Języki skryptowe

Laboratorium 3 – Podstawowe struktury danych Pythona.

Cele dydaktyczne

Zapoznanie z podstawowymi strukturami danych Pythona: listami, krotkami, słownikami.

Zadania

1. Przygotowanie i czytanie danych

Logi HTTP to pliki lub zapisy zawierające informacje o żądaniach i odpowiedziach przesyłanych między klientem a serwerem w protokole HTTP. Zawierają one dane takie jak adres IP użytkownika, metoda żądania, adres URL, kod odpowiedzi serwera oraz znacznik czasu, co pozwala na analizę ruchu sieciowego i diagnostykę problemów.

Pobierz plik z logami serwera webowego: http_first_100k.log.

https://drive.google.com/drive/folders/1tNfn31un5u4D0Ep15Ezy7fCD6bTZWx6f?usp=sharing

Zapoznaj się ze strukturą pliku, która opisana jest tutaj: https://www.secrepo.com/Datasets%20Description/Network/http.html

W szczególności, zapoznaj się z polami (pozostałe możesz ingorować):

- ts Znacznik czasu żądania w formacie UNIX timestamp (sekundy od 1970-01-01).
- **uid** Unikalny identyfikator sesji (np. dla konkretnego połączenia).
- id.orig_h Adres IP hosta wysyłającego żądanie (klienta).
- id.orig_p Port źródłowy hosta wysyłającego żądanie.
- id.resp_h Adres IP serwera, do którego skierowano żądanie.
- id.resp_p Port docelowy serwera, zwykle 80 (HTTP) lub 443 (HTTPS).
- method Metoda HTTP (GET, POST, HEAD, PUT, DELETE, OPTIONS, itp.).

1

- host Nazwa domenowa hosta serwera, do którego wysyłane jest żądanie.
- uri Ścieżka URI zasobu, który jest żądany (np. /index.html).

Przygotuj skrypt pozwalający odczytywać logi HTTP z wejścia standardowego.

2. Listy i krotki

- a. Utwórz funkcję read_log, która czyta wszystkie linie z wejścia standardowego i zwraca **listę** zawierającą poszczególne wpisy. Funkcja powinna:
 - i. Podzielić każdą linię (wpis) na niezależne elementy.
 - ii. Dokonać konwersji ciągów znaków na odpowiednie typy danych wbudowane oraz biblioteki standardowej (np. kod statusu – int, data i znacznik czasu żądania – <u>datetime.datetime</u>.
 - iii. Uwzględnić i reprezentować co najmniej atrybuty opisane powyżej,
 - iv. Zapisać każdy wpis (niepustą linię) jako krotkę na liście.
 - v. Zwrócić listę krotek.
- b. Napisz funkcję sort_log(log, index), która:
 - i. przyjmuje dwa parametry:
 - 1. log lista krotek reprezentującą wpis oraz
 - 2. index liczba określająca element krotki, według którego zostanie wykonane sortowanie.
 - ii. Zaimplementuj mechanizm sortowania listy korzystając z funkcji sorted() lub sort().
 - iii. Z wykorzystaniem mechanizmu obsługi wyjątków zadbaj o poprawność działania funkcji (np. gdy index przekroczy rozmiar krotki).
- c. Napisz funkcję get_entries_by_addr, która:
 - i. przyjmuje jako parametr listę krotek reprezentującą log,
 - ii. przyjmuje jako parametr ciąg znaków reprezentujący adres IP lub nazwę domenową hosta wykonującego żądanie,
 - iii. waliduje podany adres ip,
 - iv. zwraca listę wpisów z danym ip.
- d. Napisz funkcję get_entries_by_code, która:
 - i. przyjmuje jako parametr listę krotek reprezentującą log,
 - ii. przyjmuje jako parametr kod statusu HTTP (np. 200),
 - iii. waliduje podany kod statusu,
 - iv. zwraca listę wpisów z danym kodem statusu.
- e. Napisz funkcję get_failed_reads, która:
 - i. przyjmuje jako parametr listę krotek reprezentującą log
 - ii. tworzy oddzielne listy zawierające wpisy z kodami statusu HTTP 4xx oraz

5xx.

- iii. przyjmuje opcjonalny parametr logiczny, który określa, czy zwrócić jedną, połączoną listę czy osobne,
- iv. opcjonalnie, łączy listy w jedną
- v. zwraca odpowiedni wynik
- f. Napisz funkcję get_entires_by_extension, która:
 - i. przyjmuje jako parametr listę krotek reprezentującą log,
 - ii. przyjmuje jako parametr ciąg znaków reprezentujący rozszerzenie pliku (np. "jpg")
 - iii. zwraca wszystkie wpisy zawierające zapytania o zasoby z danym rozszerzeniem.

3. Słowniki

- a. Utwórz funkcję entry_to_dict, która:
 - i. przyjmuje na wejściu krotkę reprezentującą pojedynczy wpis
 - ii. tworzy słownik, w którym kluczem jest ciąg znaków reprezentujący znaczenie kolejnych pól wpisu, np. "ip", "status code", "ts", etc. Wartością w słowniku jest wartość danego pola.
 - iii. zwraca słownikową reprezentację pojedynczego wpisu
- b. Utwórz funkcję log_to_dict, która:
 - i. przyjmuje na wejściu listę krotek reprezentującą cały log,
 - ii. tworzy słownik, w którym kluczem jest uid reprezentujący sesję. Wartością w tym słowniku powinna być lista słowników w postaci zwracanej przez funkcję entry_to_dict.
 - iii. zwraca słownik zawierający wszystkie wpisy z listy słownikowa reprezentacja logu
- c. Utwórz funkcję print_dict_entry_dates, która:
 - i. przyjmuje na wejściu słownikową reprezentację logu
 - ii. iteruje po elementach słownika
 - iii. wyświetla na wyjściu standardowym w czytelny sposób:
 - 1. adresy ip/nazwy domenowe hostów w sesji,
 - 2. liczbę żądań wykonanych przez danego hosta,
 - 3. datę pierwszego i ostatniego żądania wykonanego przez hosta,
 - procentowy udział żądań danej metody np. (GET 30 %, POST 70%)
 - 5. stosunek liczby żądań z kodem 2xx do liczby wszystkich żądań.

Materiały dodatkowe

- 1. Alex Martelli, Anna Martelli Ravenscroft, Steve Holden, Paul McGuire, Python in a Nutshell, 4th Edition, Published by O'Reilly Media, Inc., Rozdział 3
 - [URL: https://learning.oreilly.com/library/view/python-in-a/9781098113544/]
- 2. https://docs.python.org/3/tutorial/datastructures.html